

## Importo librerias

```
In [1]: # Librerías principales
import pandas as pd
from pathlib import Path

# Configuración general
pd.set_option('display.max_columns', None)
```

## Localización Proyecto y carga de Dataset

```
In [2]: # Detectar la raíz real del proyecto (carpeta que contiene "DATA")
PROJECT_ROOT = Path.cwd().resolve()

# Si estás dentro de NOTEBOOKS, sube un nivel
if PROJECT_ROOT.name.lower() == "notebooks":
    PROJECT_ROOT = PROJECT_ROOT.parent

# Si aún no ves DATA, sube hasta encontrarla
while not (PROJECT_ROOT / "DATA").exists() and PROJECT_ROOT.parent != PROJECT_ROOT.parent:
    PROJECT_ROOT = PROJECT_ROOT.parent

# Verificación de seguridad
if not (PROJECT_ROOT / "DATA").exists():
    raise FileNotFoundError("No encuentro la carpeta 'DATA'. Abre el notebook de"

# Carga
FNAME = "dataset_limpio_y_transformado.csv"
ruta_dataset = PROJECT_ROOT / "DATA" / "DATA_OUTPUT" / FNAME

# Comprobación y carga segura
if not ruta_dataset.exists():
    # Búsqueda recursiva en caso de estar en otra subcarpeta
    hits = list(PROJECT_ROOT.rglob(FNAME))
    if hits:
        ruta_dataset = hits[0]

if not ruta_dataset.exists():
    raise FileNotFoundError(
        f"No encuentro el archivo {FNAME}. Vuelve a exportarlo a DATA/DATA_OUTPUT"
        f"Probé en: {ruta_dataset.parent}"
    )
```

 Informe del Análisis Exploratorio de  
Datos sobre operaciones financieras  
etiquetadas como fraude / no fraude

## 1. Introducción

### 1. Introducción

#### Objetivo del análisis

Realizar un **análisis exploratorio de datos (EDA)** sobre un conjunto de **operaciones financieras** para:

- **Identificar patrones, relaciones y tendencias** asociados a **fraude vs. no fraude**.
- Entender cómo variables como **comercio, tipo de comercio, nivel de riesgo (alto/medio/bajo), antigüedad, tipo de operación, tipo de tarjeta, resultado de la operación** se relacionan con la probabilidad de fraude.
- Generar **insights accionables** que ayuden a **priorizar revisiones, afinar reglas y mejorar la prevención y la gestión operativa del fraude**.

Preguntas guía:

- ¿Cuál es la **prevalencia de fraude** global y por **segmentos** (merchant / tipo de comercio / nivel de riesgo / tipo de operación)?
- ¿Existen **picos temporales** de fraude (por día/mes/hora o por antigüedad de la cuenta)?
- ¿Qué **combinaciones de variables** incrementan el riesgo.
- ¿Qué diferencias hay por variables **geográficas** (recordatorio: `region` = *región del cliente*; `country` = *país donde se realiza la operación*)?
- ¿Qué **insights** pueden convertirse en **acciones** concretas?

Estas preguntas actúan como guía del análisis y orientan la búsqueda de patrones en los datos.

Cada una de ellas se abordará a lo largo del informe mediante gráficos, métricas y conclusiones .

---

#### Contexto del dataset

El análisis parte de **dos archivos originales**:

1. **Clientes (original)** → contiene información básica del cliente: `customer_id`, nombre, email, phone, `region`, `country`, `created_at`, `risk_core`.
2. **Transacciones (original)** → recoge el detalle de operación: `transaction_id`, `customer_id`, `transaction_time`, `amount`, `currency`, `merchant`, `merchant_category`, `arn`, `entry_mode`, `card_bin6`, `card_last4`, `card_masked`, `card_tipe`, `card_expiry`, `transation_result`, `is_fraud`.

Ambos archivos se **unieron mediante una columna en común** (identificador de cliente o cuenta), dando lugar a un **único dataset consolidado** que integra tanto el perfil del cliente como la información transaccional.

El resultado de esta unión se sometió posteriormente a un proceso de **limpieza y transformación**, del cual surgió el archivo final **dataset\_limpio\_y\_transformado.csv**.

Este último representa la **fuente única de verdad** del proyecto y es el que se utiliza en el análisis exploratorio y en todo el informe.

**Alcance:** Este informe es **descriptivo** (EDA). No incluye modelos predictivos; se centra en **explorar y explicar** el comportamiento del fraude con visualizaciones y métricas descriptivas.

---

## Estructura del informe

1. **Introducción** — Objetivos, contexto y alcance.
  2. **Datos y calidad** — Estructura del dataset final y evaluación de calidad.
  3. **Principales transformaciones** — Resumen de limpieza, uniones y derivadas clave.
  4. **Análisis visual (6–8 gráficos)** — Distribuciones, comparativas y relaciones con fraude.
  5. **Insights y recomendaciones** — *Usar siempre “insights” (no “hallazgos”) y traducirlos a acciones.*
  6. **Limitaciones del estudio** — Restricciones y consideraciones del dato.
  7. **Próximos pasos** — Profundizaciones, datos adicionales y líneas de mejora.
- 
- 

## 2. Datos y calidad

### 2.1. Origen y consolidación

El análisis se ha desarrollado a partir de un conjunto de **datos sintéticos** que simulan operaciones financieras reales.

El proyecto parte de **dos fuentes iniciales**:

1. **Clientes** → información general del cliente (identificador, correo, teléfono, país, etc.).
2. **Transacciones** → operaciones financieras con detalle de comercio, importe, tipo de tarjeta, modo de entrada, nivel de riesgo y etiqueta de fraude.

Ambos conjuntos se **unieron mediante una columna en común ( customer\_id )**, generando un **dataset consolidado** que integra el comportamiento transaccional con los atributos del cliente.

Posteriormente, se llevó a cabo un proceso de **limpieza, transformación y normalización**, cuyo resultado final se guardó en el archivo:

### dataset\_limpio\_y\_transformado.csv

Este archivo constituye la **fuente única de verdad** sobre la que se ha desarrollado todo el análisis exploratorio.

---

## 2.2. Estructura y volumen

- **Filas: 39.906**
- **Columnas: 34**
- **Tasa global de fraude ( is\_fraud ): 1,10 %**

Variables relevantes:

- `is_fraud` → indicador principal (1 = fraude, 0 = no fraude).
  - `risk_level` → clasificación de riesgo (alto, medio, bajo).
  - `entry_mode` → modo de entrada de la transacción (*chip, contactless, magstripe, wallet, ecommerce*).
  - `transaction_result` → resultado de la operación (*approved, declined, pending*).
  - `card_type` → tipo de tarjeta (*VISA, MASTERCARD, AMEX, DISCOVER*).
  - `merchant_category` → categoría o tipo de comercio (*electronics, fashion, grocery, travel, etc.*).
  - `amount` → importe de la transacción.
  - `risk_score` → puntuación numérica de riesgo asignada a la transacción.
  - `region_normalized` → región de residencia o país del cliente.
  - `country_normalized` → país donde se ha realizado la operación.
  - `customer_days_active` → número de días que el cliente llevaba activo en el sistema.
- 

## 2.3. Completitud y nulos

- **Nulos totales en el dataset: 0.**
  - **Nulos por columna: ninguna columna** presenta valores nulos tras la consolidación.
- 

## 2.4. Integridad y duplicados

- **Duplicados en `transaction_id` : 0** → cada transacción es única.
  - **Relación cliente–transacción:** consistente **1-a-N** (sin pérdidas evidentes en la clave).
- 

## 2.5. Tipos y rangos (checks básicos)

- **Importe ( `amount` ):**
  - **mín:** 2,35 · **q25:** 111,76 · **mediana:** 187,69 · **q75:** 261,12 · **máx:** 656,13
  - **Importes negativos: 0**
- **Divisa ( `currency` ): EUR** (única).

- **Categorías principales:**
    - `risk_level` : Alto, Medio, Bajo
    - `entry_mode` : chip, contactless, ecommerce, magstripe, wallet
    - `transaction_result` : approved, declined, pending
    - `card_type` : AMEX, DISCOVER, MASTERCARD, VISA
    - `merchant_category` : electronics, fashion, gaming, grocery, pharmacy, restaurant, travel
- 

## 2.6. Fechas y coherencia temporal

- `transaction_date` : de 2024-10-11 a 2025-10-12
- `created_at` : de 2024-06-17 a 2026-02-02

**Chequeo de coherencia ( `transaction_date` vs `created_at` ):**

- Registros con **transacción anterior a `created_at` : 19.899.**
- Interpretación:** este comportamiento sugiere que `created_at` no representa necesariamente la “fecha de alta inicial” de la cuenta/tarjeta, sino **otro hito (p. ej., fecha de alta del perfil en sistema actual, migración o actualización)**.  
Por ello, para medir antigüedad operativa se utiliza `customer_days_active`, no la comparación directa `transaction_date < created_at`.

## 2.7. Normalización y geografía

- **País/Región:**
    - `region_normalized` (residencia del cliente) y `country_normalized` (país de operación) están **normalizados** (nombres consistentes).
    - Existe bandera `is_international` para detectar operaciones fuera del país del cliente.
  - **Codificaciones en minúsculas/estandarizadas** en: `entry_mode` , `transaction_result` , `merchant_category` .
- 

## 2.8. Conclusión

El dataset final presenta **excelente completitud (0 nulos)**, **unicidad por transacción**, valores monetarios **dentro de rangos plausibles** y categorías **bien estandarizadas**. La única consideración de calidad es la **interpretación de `created_at`**, que no debe usarse como “fecha de alta original” al comparar con `transaction_date` ; para antigüedad se dispone de `customer_days_active` .  
Con estas garantías, el conjunto es adecuado para analizar el **comportamiento del fraude** por riesgo, tarjeta, comercio, geografía y resultado de la operación.

---

---



## 3. Principales transformaciones

### 3.1. Consolidación de fuentes

- **Unión** de los dos orígenes (clientes + transacciones) mediante `customer_id`.
  - Se conservó **toda la casuística transaccional** (join 1–N desde transacciones), generando un único dataset consolidado.
  - Resultado de la consolidación: `dataset_limpio_y_transformado.csv` (fuente única del EDA).
- 

### 3.2. Conversión de tipos

- **Fechas** a `datetime`: `transaction_date`, `created_at`.
  - **Numéricos**: `amount` y `risk_score` a tipo numérico.
  - **Categóricas**: `risk_level`, `entry_mode`, `transaction_result`, `card_type`, `merchant_category`, `region_normalized`, `country_normalized`.
- 

### 3.3. Normalización y estandarización de categorías

- **Etiquetas consistentes** en:
    - `risk_level` → **Alto / Medio / Bajo**
    - `entry_mode` → **chip / contactless / ecommerce / magstripe / wallet**
    - `transaction_result` → **approved / declined / pending**
    - `card_type` → **AMEX / DISCOVER / MASTERCARD / VISA**
  - **Geografía normalizada**:
    - `region_normalized` = país/región del cliente (normalizado).
    - `country_normalized` = país de la operación (normalizado).
    - `is_international` = indicador si `country_normalized` ≠ `region_normalized`.
- 

### 3.4. Variables temporales derivadas

- Desde `transaction_date` se generaron:
    - `month` (1–12), `weekday` (0–6), `hour` / `transaction_hour`, `month_year` (etiqueta Y–M).
  - Objetivo: habilitar **series temporales**, estacionalidad y análisis por franjas horarias.
- 

### 3.5. Antigüedad operativa del cliente

- `customer_days_active`: días de actividad del cliente disponibles en el dataset y utilizados para los análisis por madurez.
- **Nota técnica:** Se intentó calcular la antigüedad restando `transaction_date` – `created_at`, pero se detectaron valores **negativos** en una parte significativa de los

registros. Esto ocurre porque `created_at` no representa la fecha de alta original, sino una fecha más reciente (posiblemente de migración o actualización de sistema). Por ello, se decidió **no utilizar esa resta directa** y en su lugar emplear la variable `customer_days_active`, que refleja correctamente los días de actividad acumulados del cliente.

---

### 3.6. Campos de tarjeta y comercio

- **Tarjeta:** `card_type` (marca), `card_bin6`, `card_last4`, `card_masked`, `card_expiry` (soporte analítico/operativo).
  - **Comercio:** `merchant` y `merchant_category` (electronics, fashion, gaming, grocery, pharmacy, restaurant, travel).
- 

### 3.7. Controles de calidad posteriores a las transformaciones

Se identificaron **filas incompletas** en las que únicamente figuraba el campo `TransactionID`, mientras que el resto de columnas se encontraban vacías. Estas filas se eliminaron al no aportar información analítica.

- **Nulos:** **0** nulos en el dataset (todas las columnas).
  - **Duplicados** en `transaction_id`: **0**.
  - **Importes** (`amount`): rango **[2.35 ; 656.13]**, sin valores negativos.
  - **Fechas:** `transaction_date` en **[2024-10-11 ; 2025-10-12]**; `created_at` en **[2024-06-17 ; 2026-02-02]**.  
Se documenta la **possible desalineación semántica** de `created_at` (no usar como "alta original").
- 

### 3.8. Filtros y decisiones de conservación

- Se conservaron **todas las categorías** de `entry_mode`, `transaction_result`, `card_type` y `merchant_category` para mantener representatividad.
- 

### 3.9. Agrupaciones clave empleadas en el EDA (sin modificar el dataset)

En este notebook se desarrollaron distintos **análisis cruzados y resúmenes estadísticos** orientados a identificar patrones de fraude en la base de datos. Cada cruce se diseñó con una finalidad analítica específica, priorizando la relación entre variables clave como `is_fraud`, `merchant_category`, `entry_mode`, `risk_level`, y `risk_score`.

---

#### Tablas y cruces analíticos realizados

Tabla / Variable derivada	Descripción	Métricas calculadas	Enfoque
<code>res_merchant</code>	Agrupación por <b>categoría de comercio</b> ( <code>merchant_category</code> ).	Número total de operaciones, fraude, tasa de fraude, importe medio/mediano, riesgo medio, peso de operaciones y fraude.	Identificar los <b>sectores con mayor exposición al fraude</b> .
<code>res_merchant_by_type</code>	Agrupación doble por <b>tipo de comercio y tipo de transacción (fraude/no fraude)</b> .	Importe medio, importe mediano, riesgo medio.	Comparar el <b>comportamiento económico de fraudes vs no fraudes</b> por sector.
<code>top_by_rate</code>	Ranking de las categorías con <b>mayor tasa de fraude</b> .	Tasa de fraude ordenada descendente.	Determinar los <b>comercios prioritarios en vigilancia antifraude</b> .
<code>plot_df</code> (comparativa fraude vs no fraude)	Filtrado de los 10 principales comercios por volumen.	Importe medio agrupado por tipo de transacción.	Analizar la <b>variación de importes medios</b> entre fraudes y operaciones legítimas.
<code>fraude_por_entry</code>	Agrupación por <b>modo de entrada</b> ( <code>entry_mode</code> ).	Porcentaje de fraude por tipo de operación.	Evaluar <b>qué canales presentan mayor incidencia de fraude</b> .
<code>freq_entry</code>	Frecuencia total de operaciones por modo de entrada.	Porcentaje de uso.	Relacionar el <b>volumen operativo con la tasa de fraude</b> .
<code>analisis_entry</code>	Unión de <code>fraude_por_entry</code> y <code>freq_entry</code> .	Tasa de fraude (%) y frecuencia de uso (%).	Permite visualizar la <b>relación entre popularidad del canal y su vulnerabilidad</b> .
<code>tabla_entry_risk</code>	Cruce entre <b>entry_mode y risk_level</b> mediante tabla cruzada.	Distribución porcentual de niveles de riesgo (Alto, Medio, Bajo) por canal.	Determinar <b>qué modos de entrada concentran mayor proporción de riesgo alto o medio</b> .

Tabla / Variable derivada	Descripción	Métricas calculadas	Enfoque
resumen_entry	Síntesis final de prevalencia y volumen por entry_mode .	Número de operaciones y tasa de fraude.	Combinar <b>exposición (volumen)</b> y <b>prevalencia (fraude)</b> en una misma visión global.

## Objetivo de las agrupaciones y cruces

El propósito de las agrupaciones desarrolladas en este notebook es ofrecer una **visión analítica integral del fraude**, combinando indicadores de frecuencia, valor económico y riesgo operativo.

### ⌚ Objetivos específicos:

#### 1. Detectar patrones de fraude por tipo de comercio

- Identificar los sectores con **mayor tasa y volumen de fraudes**.
- Determinar si los fraudes se concentran en operaciones de alto importe o riesgo.

#### 2. Evaluar la influencia del canal de entrada ( entry\_mode ) en la probabilidad de fraude

- Analizar qué métodos (wallet, magstripe, chip, etc.) presentan **mayor vulnerabilidad**.
- Relacionar el uso masivo de ciertos canales con la efectividad de los controles.

#### 3. Examinar la relación entre riesgo y fraude

- A través de la tabla entry\_mode vs risk\_level , se identifican los **modos con mayor proporción de riesgo medio-alto**, reforzando el análisis predictivo.

#### 4. Relacionar volumen de operaciones y prevalencia de fraude

- Mediante resúmenes combinados, se detectan canales con **alta actividad operativa y elevada incidencia de fraude**, priorizando la mitigación en esos puntos.

#### 5. Visualizar hallazgos mediante gráficos y rankings claros

- Las visualizaciones (heatmaps, barras comparativas y rankings) aportan una **visión inmediata de las áreas críticas**, favoreciendo la toma de decisiones basada en datos.

Estos análisis constituyen la base de los **gráficos e insights** que se desarrollan posteriormente en el informe.

**Resultado:** tras estas transformaciones, el dataset quedó **coherente, completo (0 nulos)** y con variables **normalizadas y derivadas** que permiten explicar el fraude por

**canal, riesgo, tarjeta, comercio, geografía, temporalidad y resultado** sin pérdida de información.

---

---



## Visualizaciones Exportadas (EDA)

Este apartado recoge las visualizaciones generadas durante el análisis exploratorio del dataset de operaciones fraudulentas. Las gráficas se organizan por temática para facilitar una lectura coherente del comportamiento del fraude en el tiempo, por canal de entrada, por tipo de comercio y por segmentos relevantes.

---



### 1. Distribución temporal de operaciones

#### 1.1 Operaciones fraudulentas por día

- Archivo: `Operaciones_fraudulentas_dia.png`
- Permite identificar patrones diarios en la actividad fraudulenta.
- Ayuda a detectar picos anómalos.

#### 1.2 Operaciones fraudulentas por hora del día

- Archivo: `Operaciones_fraudulentas_hora_dia.png`
- Muestra las franjas horarias con mayor incidencia de fraude.

#### 1.3 Operaciones fraudulentas por semana

- Archivo: `Operaciones_fraudulentas_semana.png`
- Evalúa tendencias semanales y posibles aumentos recurrentes.

#### 1.4 Distribución de fraudes por mes

- Archivo: `Distribucion_fraudes_por_mes.png`
  - Mide la estacionalidad del fraude por mes.
- 



### 2. Análisis por modo de entrada (Entry Mode)

#### 2.1 Distribución general por entry mode

- Archivo: `Distribucion_general_entry_mode.png`
- Muestra cómo se distribuyen las operaciones según el método de entrada.

#### 2.2 Entry mode vs nivel de riesgo

- Archivo: `entrymode_risklevel.png`

- Permite ver si ciertos modos de entrada concentran operaciones de mayor *risk\_score*.
- 



## 3. Análisis por tipo de comercio y categoría

### 3.1 Operaciones por tipo de tarjeta y comercio

- Archivo: `operaciones_tipo_tarjeta_comercio.png`
- Relaciona tipos de tarjeta con categorías de comercio.

### 3.2 Importe medio por categoría (Fraude vs No fraude)

- Archivo: `importe_medio_fraude_vs_no_fraude_top10.png`
- Compara los importes medios entre operaciones fraudulentas y no fraudulentas.

### 3.3 Fraude por tipo de tarjeta

- Archivo: `fraude_por_tipo_tarjeta.png`
- Identifica qué tarjetas presentan mayor proporción de fraude.

### 3.4 Top países por volumen de fraude

- Archivo: `top_paises_volumen_operaciones_fraude.png`
- Muestra los países con mayor concentración de operaciones fraudulentas.

### 3.5 Distribución geográfica del risk\_score

- Archivo: `geo_risk_score_violin.png`
  - Analiza la distribución del *risk\_score* por región o país.
- 



## 4. Comparativas de fraude y análisis avanzado

### 4.1 Comparativa general de fraude

- Archivo: `comparativa_fraude.csv`
- Resumen estadístico del comportamiento global de fraude vs no fraude.

### 4.2 Tasa de fraude por nivel de riesgo

- Archivos:
  - `amount_por_risk_level.csv`
  - `amount_por_risk_level.png`
- Relacionan riesgo y volumen económico.

### 4.3 Distribución del fraude

- Archivo: `distribucion_fraude.csv`

- Tabla descriptiva complementaria al análisis visual.

## 4.4 Tasa de fraude por merchant (Top N)

- Archivo: `tasa_fraude_topN_merchant.png`
- Identifica comercios con mayor tasa relativa de fraude.

## 4.5 Fraude por resultado de transacción

- Archivo: `fraude_por_resultado_transaccion.png`
- Analiza el fraude según el resultado de la operación.



## 5. Resumen estadístico

- Archivo: `resumen_estadistico.csv`
- Incluye estadísticas descriptivas de las principales variables numéricas del dataset.



## 4. Análisis visual

A continuación se presentan las principales visualizaciones del análisis exploratorio, centradas en la detección de patrones de fraude según canal, tipo de tarjeta, riesgo, comercio, resultado y evolución temporal.

Cada gráfico incluye una breve interpretación ("insight") basada en los datos del EDA.



### 1. Relación entre frecuencia de uso y tasa de fraude según el modo de entrada ( `entry_mode` )

Distribución por `entry_mode`

El gráfico muestra la **relación entre el porcentaje total de operaciones** y la **tasa de fraude** para cada tipo de modo de entrada (`entry_mode`), representando así tanto la **popularidad de uso** como el **riesgo relativo** asociado a cada canal de transacción.

Esta visualización permite identificar **qué modo de entrada concentra mayor volumen de uso y en cuáles se presenta una mayor proporción de fraude**.



**Insights:**

#### 1. `wallet` (billeteras digitales)

- Es el canal con **mayor frecuencia de uso ( $\approx 20\%$ )** y también muestra la **tasa de fraude más elevada ( $\approx 1.28\%$ )**.

- Indica que, aunque es el medio más utilizado, **representa un foco importante de riesgo** y requiere un seguimiento reforzado.

## 2. **magstripe y contactless**

- Mantienen una participación similar ( $\approx 19\text{--}20\%$  de operaciones), con tasas de fraude algo menores ( $\approx 1.1\text{--}1.15\%$ ).
- Se consideran **canales moderadamente seguros**, aunque su alto volumen los convierte en **zonas potenciales de exposición**.

## 3. **ecommerce**

- A pesar de su **volumen de uso cercano al 20%**, presenta una **tasa de fraude inferior ( $\approx 0.98\%$ )**.
- Esto sugiere que **las medidas antifraude implementadas en pagos online están resultando efectivas**, o bien que las transacciones sospechosas son detectadas antes de completarse.

## 4. **chip (EMV)**

- Es el canal **más seguro**, con la **tasa de fraude más baja ( $\approx 0.96\%$ )**.
- Este resultado es consistente con la tecnología de chip, que incorpora **mecanismos criptográficos más robustos** frente a clonaciones y usos indebidos.

## Conclusiones

- Existe una **tendencia descendente clara**: a mayor seguridad tecnológica del método de entrada, menor es la tasa de fraude.
  - Sin embargo, los canales **más cómodos o rápidos para el usuario** (wallet y contactless) tienden a ser **más susceptibles a intentos de fraude**.
  - Estos resultados pueden utilizarse para **priorizar controles o campañas de prevención** según el canal de entrada más expuesto.
- 

## 2. Porcentaje de fraude por tipo de tarjeta (card\_type)

### Fraude por tipo de tarjeta

El gráfico muestra la **tasa de operaciones fraudulentas (%)** según el tipo de tarjeta utilizada, permitiendo identificar **qué marcas presentan mayor vulnerabilidad** frente al fraude.

### Insights:

#### 1. AMEX

- Registra la **tasa de fraude más alta ( $\approx 1.38\%$ )**, superando ligeramente al resto.
- Este resultado podría estar asociado a su **perfil de cliente más internacional** y al uso frecuente en **entornos digitales o de alto importe**, donde la exposición

al fraude suele ser mayor.

## 2. MASTERCARD

- Presenta una tasa de fraude similar ( $\approx 1.32\%$ ).
- Aunque ampliamente distribuida, su uso masivo en distintos comercios la convierte en un **objetivo habitual de intentos de fraude**.

## 3. DISCOVER

- Muestra una tasa intermedia ( $\approx 1.18\%$ ), manteniendo un comportamiento relativamente estable.
- Indica una **exposición moderada**, posiblemente por su menor volumen de operaciones globales.

## 4. VISA

- Es la tarjeta **con menor tasa de fraude ( $\approx 0.90\%$ )**, lo que sugiere **mayor efectividad de sus controles antifraude y autenticación**.
- Puede relacionarse con una **amplia red de detección temprana** y adopción de estándares EMV en la mayoría de sus operaciones.

## ❖ Conclusiones

- Se observa una **brecha de riesgo de aproximadamente 0.5 puntos porcentuales** entre la marca más vulnerable (AMEX) y la más segura (VISA).
- Las diferencias pueden deberse tanto a **estrategias de control de riesgo propias de cada red** como a la **naturaleza de los clientes y comercios asociados**.
- Este análisis permite **priorizar la vigilancia y los controles adicionales** en los tipos de tarjeta con mayor tasa de fraude detectada.

---

## 3. Tipo de comercio × tipo de tarjeta (merchant\_category × card\_type)



El gráfico muestra el **reparto porcentual de las operaciones por tipo de tarjeta dentro de cada categoría de comercio**, permitiendo analizar la **preferencia de uso de las distintas marcas** (AMEX, DISCOVER, MASTERCARD y VISA) según el sector.

## ❖ Insights:

### 1. Predominio de VISA

- VISA concentra la **mayor proporción de operaciones** en todos los sectores analizados, superando aproximadamente el **45–50% del total de transacciones**.
- Esto la posiciona como la **tarjeta más utilizada por los clientes**, reflejando su amplia aceptación y cobertura internacional.

### 2. MASTERCARD con fuerte presencia

- Representa cerca de un **30–35% de las operaciones**, manteniendo un peso significativo en todos los tipos de comercio.
- Su cuota estable sugiere **una alta penetración en comercios generalistas y minoristas**.

### 3. AMEX y DISCOVER con uso limitado

- Ambas presentan participaciones menores, en torno al **8–10% cada una**, con ligeras variaciones por sector.
- El uso de **AMEX** tiende a ser más elevado en **moda, viajes y restauración**, sectores asociados a **gasto medio-alto y clientes internacionales**.
- **DISCOVER**, en cambio, mantiene una presencia más homogénea pero reducida, concentrada en **pagos online o de nicho**.

## Conclusiones

- El mercado muestra una **clara concentración de operaciones en las redes VISA y MASTERCARD**, lo que puede implicar una **mayor exposición agregada al riesgo** en estos emisores.
  - Los comercios de **viajes, restauración y moda** son los que presentan **mayor diversidad de marcas**, posiblemente por su **perfil de cliente internacional**.
  - Esta distribución es útil para **evaluar la exposición al fraude por tipo de producto y sector**, especialmente al cruzarla con la **tasa de fraude por tarjeta** obtenida en el análisis anterior.
- 

## 4. Modo de entrada x nivel de riesgo (entry\_mode x risk\_level)



El mapa de calor muestra la **distribución porcentual de los niveles de riesgo (Alto, Medio, Bajo)** según el **modo de entrada de la transacción (entry\_mode)**, ofreciendo una visión clara de qué canales presentan mayor concentración de riesgo.

### Insights:

#### 1. Predominio del nivel de riesgo medio ( $\approx 40\text{--}42\%$ )

- En todos los modos de entrada, **el riesgo medio es el más frecuente**, lo que sugiere una **exposición moderada generalizada** en las operaciones.
- Este patrón indica que, aunque no hay un riesgo extremo predominante, **los canales mantienen una vulnerabilidad constante**.

#### 2. magstripe muestra el mayor riesgo relativo (42% medio)

- Las transacciones con **banda magnética** concentran el porcentaje más alto de operaciones en nivel de riesgo medio.
- Esto confirma que **los métodos más antiguos presentan mayor vulnerabilidad** frente a fraude o anomalías.

### 3. ecommerce y wallet mantienen un perfil equilibrado

- Ambos presentan distribuciones muy próximas al promedio ( $\approx$ 41% medio, 31% alto, 27–28% bajo).
- Muestran un **riesgo moderado y estable**, propio de canales digitales que aplican validaciones adicionales.

### 4. chip y contactless exhiben perfiles de riesgo controlados

- Con una proporción similar de riesgo alto ( $\approx$ 31–32%) y bajo ( $\approx$ 27–28%).
- Esto respalda la **efectividad de las tecnologías EMV y sin contacto** en la reducción del riesgo operativo.

## ✳ Conclusiones

- Existe una **consistencia en la distribución de niveles de riesgo entre canales**, con predominio del **riesgo medio**, lo que sugiere una exposición homogénea.
- **Magstripe** sigue siendo el **modo de entrada más sensible**, lo que justifica **acciones preventivas específicas o migración tecnológica** hacia métodos más seguros.
- Este análisis permite **priorizar controles antifraude por canal**, alineando los esfuerzos de mitigación con la exposición al riesgo observada.

## 💡 5. Porcentaje de fraude por resultado (transaction\_result)

### Fraude por resultado

El gráfico representa el **porcentaje de operaciones fraudulentas** según el **resultado final de la transacción** (aprobada, pendiente o declinada).

Permite evaluar la **efectividad de los filtros de autorización** y entender en qué fase se concentran las tentativas de fraude.

### Insights:

#### 1. Transacciones declinadas → mayor tasa de fraude ( $\approx$ 2.07%)

- La mayoría de las operaciones fraudulentas se concentran en las **transacciones rechazadas**.
- Esto indica que **los controles antifraude están actuando correctamente**, detectando comportamientos sospechosos antes de que la operación se autorice.

#### 2. Transacciones pendientes → riesgo intermedio ( $\approx$ 1.28%)

- Los casos en espera representan una fracción relevante de operaciones potencialmente fraudulentas.
- Es un grupo a **monitorizar con especial atención**, ya que podrían incluir transacciones legítimas bajo revisión o intentos de fraude no confirmados.

### 3. Transacciones aprobadas → menor tasa de fraude ( $\approx 1.01\%$ )

- El porcentaje más bajo se encuentra entre las **operaciones autorizadas**, lo que evidencia una **eficiente capa de prevención y filtrado previo**.
- Sin embargo, sigue existiendo una fracción de fraude residual que **consigue superar los filtros iniciales**.

## ❖ Conclusiones

- El análisis demuestra una **buena eficacia de los mecanismos de detección temprana**, que bloquean la mayoría de los intentos antes de su aprobación.
- No obstante, el **1% de fraude aprobado** evidencia la necesidad de **reforzar controles en tiempo real y post-autorización**.
- En conjunto, este comportamiento refleja una **operativa madura de prevención**, pero con **margin de mejora en los casos límitrofes** (pendientes o borderline).

## ⌚ 6. Evolución temporal de transacciones (día)



El gráfico presenta la **distribución diaria de las operaciones fraudulentas dentro de cada mes**, lo que permite analizar la **variabilidad del fraude a lo largo del ciclo mensual** y detectar posibles patrones de comportamiento.

## 📈 Insights:

### 1. Mayor concentración entre los días 1–5 y 24–27 del mes

- Los **inicios y finales de mes** muestran un aumento notable de operaciones fraudulentas (picos de 19 a 21 casos).
- Este patrón puede relacionarse con **cierres de facturación, ciclos de nómina o movimientos financieros habituales**, momentos donde los defraudadores buscan camuflar sus operaciones entre transacciones legítimas.

### 2. Descensos pronunciados hacia los días 10–12 y 18–22

- En la parte media del mes se observan varios descensos (con mínimos de 3 y 8 casos).
- Esto puede indicar **periodos de menor actividad económica** o una **mejor eficacia de los sistemas de control** en esos intervalos.

### 3. Actividad irregular pero con repeticiones cíclicas

- Se aprecia un **ritmo de repunte cada 8–10 días**, lo que podría reflejar **patrones de prueba o “testing” de fraudes recurrentes**.

## ❖ Conclusiones

- El fraude presenta una **dinámica cíclica dentro del mes**, con **mayor intensidad en los extremos del periodo**.

- Este comportamiento sugiere que los atacantes **aprovechan los momentos de mayor volumen transaccional** (cobros, pagos, cierres contables).
  - Se recomienda **reforzar los controles automáticos y alertas preventivas** durante los **primeros y últimos cinco días del mes**, cuando la exposición al riesgo es más elevada.
- 

## ⌚ 7. Evolución temporal de transacciones (hora/día)



El gráfico combina la **cantidad total de operaciones por hora del día** (barras verdes) con la **tasa de fraude (%)** asociada (línea roja).

Este enfoque permite identificar **horas críticas del día** donde el volumen operativo y el fraude no siguen el mismo patrón.



### 1. Mayor tasa de fraude entre las 2:00 y las 3:00 h ( $\approx 3\%$ )

- A pesar del bajo volumen de operaciones, el porcentaje de fraude es muy alto.
- Este comportamiento sugiere **actividad fraudulenta concentrada en horas de baja supervisión**, posiblemente aprovechando la menor carga operativa de control.

### 2. Segundo pico relevante hacia las 15:00 h ( $\approx 3\%$ )

- Coincide con un horario de **alta actividad comercial**, lo que indica que los intentos de fraude **aumentan durante períodos de mayor flujo de transacciones**.

### 3. Franja de menor riesgo: entre las 10:00 y las 13:00 h

- Durante las horas laborales estándar, tanto el volumen como la tasa de fraude descienden.
- Esto puede asociarse a **mejoras en los controles activos o mayor atención de los equipos de revisión manual**.

### 4. Alta actividad de operaciones entre 8:00 y 20:00 h, pero sin correlación directa con el fraude.

- La mayor parte del volumen se concentra en horas diurnas, aunque la tasa de fraude **permanece moderada**.
- Indica que **el riesgo no depende solo del volumen**, sino de **comportamientos específicos en franjas concretas**.



- El fraude muestra **dos patrones horarios bien diferenciados**:
  - **Nocturno (2-3 h)**: fraude oportunista en baja actividad.
  - **Vespertino (15 h)**: fraude en picos de alto tráfico comercial.

- Se recomienda **reforzar los sistemas de detección en tiempo real** durante estas franjas críticas, aplicando controles dinámicos por hora.
  - El análisis demuestra que **la vigilancia continua no debe ser homogénea**, sino **adaptativa según el riesgo horario**.
- 

## ⌚ 8. Tasa de fraude por país del comercio.



El gráfico muestra el **porcentaje de operaciones fraudulentas por país del comercio**, considerando los **10 países de los comercios con mayor volumen de transacciones**. El objetivo es identificar **regiones con mayor propensión al fraude**, así como evaluar si existe **correlación entre el volumen transaccional y la incidencia delictiva**.

### 📈 Insights:

#### 1. Mayores tasas de fraude en:

- **Netherlands Antilles (1.9%), Spain (1.95%) y China (1.75%).**
  - Estos países presentan **niveles de fraude muy por encima del promedio** del grupo.
  - En el caso de España, la cifra elevada podría estar relacionada con **el alto volumen operativo local y la diversidad de canales de pago**.
  - En China y Antillas Neerlandesas, podría influir la **exposición a transacciones internacionales y comercio electrónico**.

#### 2. Riesgo medio en:

- **Canada (1.2%), Switzerland (1.15%), Eritrea (1.28%) y Qatar (0.8%).**
  - Estos países mantienen una **actividad moderada pero estable**, lo que indica **riesgo controlado pero persistente**.

#### 3. Menor exposición en:

- **Korea (0.5%), Tonga (0.65%) y Jordan (0.95%).**
  - Estos mercados reflejan **baja incidencia de fraude**, posiblemente por **marcos regulatorios más estrictos o menor presencia transaccional internacional**.

## ✳️ Conclusiones

- El comercio con fraude **no se distribuye de forma uniforme entre los países**: algunos mercados presentan **tasas elevadas sin necesariamente tener más volumen**, lo que evidencia **factores específicos de vulnerabilidad**.
- Se recomienda **analizar la naturaleza de las operaciones internacionales** en países de alto riesgo (p. ej., **España, China y Antillas Neerlandesas**) para identificar **posibles patrones de fraude transfronterizo**.
- Este análisis geográfico es clave para **priorizar controles adaptados al contexto regional**, reforzando la detección temprana en los países de los comercios con

**mayor exposición o comportamiento atípico.**

---

---

## Conclusión general del proyecto y utilidad

### 1. Síntesis global del flujo de trabajo

El proyecto se ha estructurado en cuatro notebooks encadenados que conforman un flujo de trabajo completo y reproducible de Análisis Exploratorio de Datos (EDA) aplicado a operaciones financieras con etiqueta de fraude:

#### 1. 01\_EDA\_PRELIMINAR

- Carga de los ficheros originales de clientes y operaciones.
- Verificación de la raíz del proyecto y definición de rutas de trabajo.
- Comprobación de columnas comunes y unión de los datasets a través de la clave de cliente.
- Generación de un primer dataset consolidado y guardado en la capa `DATA_RAW_OUTPUT`.

#### 2. 02\_EDA\_LIMPIEZA\_TRANSFORMACION

- Revisión sistemática de tipos de datos, nulos y valores atípicos.
- Normalización de valores vacíos en variables categóricas (`' '`, `' '`, `null`, `None`, `NA`, etc.) a `NaN`.
- Eliminación o tratamiento de filas sin información útil (p.ej., registros con solo `transaction_id`).
- Conversión de columnas de fecha y numéricas a tipos adecuados, garantizando coherencia temporal y monetaria.
- Creación de variables derivadas (por ejemplo, categorización de niveles de riesgo y otras variables auxiliares).
- Ordenación y homogeneización del orden de columnas.
- Guardado del **dataset limpio y transformado** en la capa `DATA_OUTPUT/EDA`.

#### 3. 03\_EDA\_ANALISIS\_DESCRIPTIVO

- Carga del dataset limpio y configuración global de parámetros de visualización.
- Definición de funciones de utilidad para guardar gráficos (`.png`) y tablas (`.csv`) de forma consistente.
- Análisis descriptivo por bloques:
  - **Distribución temporal** (día, hora, semana, mes).
  - **Entry mode / canal de entrada** y su relación con el riesgo.
  - **Tipo de comercio y tipo de tarjeta** (distribuciones cruzadas, porcentajes, top categorías).
  - **Distribución geográfica** y análisis de países con mayor volumen de fraude.

- **Comparativas fraude vs no fraude** (tanto en volumen como en importes medios).
- **Evaluación del risk\_score** mediante deciles y niveles, analizando si el modelo discrimina bien el fraude.
- Exportación ordenada de todas las salidas a `DATA/DATA_OUTPUT/EDA` .

#### 4. 04\_INFORME

- Integración narrativa de todo el trabajo previo en un informe estructurado.
- Descripción del origen de los datos, criterios de limpieza y principales transformaciones.
- Inclusión de las visualizaciones exportadas y su interpretación cualitativa.
- Redacción de síntesis y apartados explicativos orientados a negocio y a la toma de decisiones.

En conjunto, los cuatro notebooks constituyen un pipeline claro: **de datos crudos a informe analítico listo para stakeholders**, con trazabilidad completa de cada paso.

---

## 2. Principales hallazgos del análisis

A partir del dataset limpio y del conjunto de visualizaciones generadas, se pueden destacar las siguientes conclusiones de alto nivel:

### 1. Distribución temporal del fraude

- El desglose por día, semana, hora y mes permite detectar picos de actividad fraudulenta y patrones recurrentes.
- Estos patrones temporales son clave para reforzar recursos de monitorización en ventanas de mayor riesgo (franjas horarias concretas, determinados días de la semana o períodos del año).

### 2. Importancia del modo de entrada (entry mode)

- El análisis por `entry_mode` muestra que no todos los canales tienen el mismo comportamiento de riesgo.
- Los modos de entrada asociados a operaciones no presenciales o con menor verificación suelen concentrar una proporción relativamente mayor de fraude, lo que justifica reglas y límites específicos por canal.

### 3. Diferencias según tipo de comercio y categoría

- El estudio por categorías de comercio y por tipo de tarjeta permite identificar sectores especialmente sensibles al fraude.
- Las comparativas de **importe medio (fraude vs no fraude)** por categoría revelan que, en algunas verticales, las operaciones fraudulentas se asocian a tickets medios distintos de los regulares (más altos en ciertos segmentos, similares o incluso inferiores en otros), lo que ayuda a diseñar umbrales de alerta más precisos.
- El análisis de comercios con mayor tasa relativa de fraude (top N merchants) facilita la priorización de revisiones y medidas de mitigación específicas por

comercio.

#### 4. Dimensión geográfica del riesgo

- Las visualizaciones por país y la distribución geográfica del `risk_score` muestran que el fraude no se distribuye de forma homogénea.
- Algunos países o regiones concentran un mayor volumen de operaciones fraudulentas o un perfil de riesgo más elevado, lo que sugiere la necesidad de políticas diferenciadas por geografía (controles adicionales, límites por país, etc.).

#### 5. Evaluación crítica del `risk_score` y sus deciles

- El análisis por deciles de `risk_score` y por niveles de riesgo revela que la tasa de fraude **no crece de forma perfectamente monótona** del decil 1 al decil 10.
- Se observan deciles intermedios (por ejemplo, el segundo y algunos deciles altos) con tasas de fraude comparables o incluso superiores a las del decil máximo.
- Esta falta de escalada perfecta sugiere que:
  - el modelo de scoring puede requerir recalibración,
  - podrían faltar variables explicativas relevantes, o
  - el patrón de fraude ha cambiado con el tiempo (drift).
- El resultado es especialmente valioso porque no solo describe el comportamiento del fraude, sino que **evalúa la calidad del modelo de riesgo existente**.

#### 6. Comportamiento global fraude vs no fraude

- La comparación sistemática entre operaciones fraudulentas y no fraudulentas (en volumen, importe medio, distribución por canales, países, categorías y resultados de transacción) permite construir un perfil diferencial del fraude.
- Este perfil sirve como base para diseñar reglas, modelos predictivos y dashboards que se centren en los factores con mayor poder discriminante.

---

### 3. Utilidad del proyecto para negocio y para análisis de datos

Este proyecto no se limita a un ejercicio académico de EDA, sino que aporta una **base práctica y reutilizable** para equipos de operaciones, riesgo y analítica:

#### 1. Base de datos limpia y documentada

- El dataset final se encuentra **limpio, normalizado y enriquecido** con variables derivadas (niveles de riesgo, categorías, etc.).
- La documentación de cada transformación facilita su reutilización en futuros proyectos (por ejemplo, modelos de clasificación de fraude, reporting recurrente o integración con herramientas como Power BI).

#### 2. Repositorio de visualizaciones clave

- La carpeta `DATA/DATA_OUTPUT/EDA` actúa como un **catálogo de gráficos y tablas** que cubre las principales dimensiones del fraude: tiempo, canal, comercio, país, tipo de tarjeta, resultado de la operación y score de riesgo.
- Estas salidas pueden incorporarse directamente a informes ejecutivos, presentaciones internas o dashboards interactivos.

### 3. Marco analítico para la toma de decisiones

- El análisis muestra qué combinaciones de variables (entry mode, país, categoría de comercio, tipo de tarjeta, nivel de riesgo, etc.) son más relevantes para entender el fraude.
- Esto permite:
  - redefinir reglas de negocio,
  - ajustar límites de autorización,
  - priorizar investigaciones manuales,
  - y focalizar recursos en segmentos de mayor impacto.

### 4. Evaluación y mejora de modelos de riesgo

- El trabajo sobre los deciles de `risk_score` y la comparativa de tasas de fraude por nivel de riesgo ofrece una **evaluación objetiva del desempeño del score actual**.
- A partir de estos resultados se pueden plantear:
  - recalibraciones del modelo,
  - incorporación de nuevas variables,
  - o incluso el diseño de modelos alternativos (por ejemplo, usando técnicas de machine learning sobre el dataset ya preparado).

### 5. Reproducibilidad y buenas prácticas de Data Analytics

- La separación en cuatro notebooks (preliminar, limpieza/transformación, análisis descriptivo e informe) sigue un esquema profesional de proyecto de datos.
  - El uso de rutas relativas, funciones de guardado, estructura de carpetas y sintaxis clara en Markdown facilita que otro analista pueda entender, ejecutar y extender el proyecto sin depender de conocimiento tácito.
- 

## 4. Cierre

En resumen, el proyecto consigue:

- transformar datos dispersos de clientes y operaciones en un **dataset integrado y de calidad**,
- realizar un **análisis exploratorio profundo** que revela patrones temporales, geográficos, de canal y de negocio en el fraude,
- y proporcionar una **base sólida para la toma de decisiones y el diseño de futuros modelos y dashboards**.

La combinación de limpieza rigorosa, análisis visual y evaluación crítica del `risk_score` convierte este trabajo en una herramienta de gran valor para cualquier área de fraude y

riesgo que quiera **entender mejor su operativa y mejorar sus estrategias de prevención.**

---

---

## Informe del dashboard de fraude realizado en Power BI

Este informe resume, en formato narrativo, los principales resultados obtenidos a partir del dashboard de fraude desarrollado en Power BI. A partir de los indicadores y visualizaciones, se describe cómo se comporta el fraude en términos de volumen, importes, países del comercio, canales de entrada y perfil del cliente.

---

### 1. Visión general del fraude

El primer panel ofrece una visión global de la situación del fraude en el conjunto de operaciones analizadas. La **tasa global de fraude** se sitúa en torno al **1,1 %**, con aproximadamente **438 operaciones fraudulentas**, lo que supone un **importe total de fraude cercano a 7,19 millones de euros**.

A pesar de esta cifra, el sistema de control y prevención muestra capacidad de contención: la **tasa de fraude aprobado** es muy reducida (en torno al **0,01 %**), y se observa un **importe de fraude evitado cercano al millón de euros**, con unas **60 operaciones de fraude evitado**. Esto indica que una parte relevante de los intentos de fraude es detectada y bloqueada antes de que la operación llegue a consolidarse.

El **flujo de operaciones por etapa** muestra que, sobre un volumen total de alrededor de **39,9 mil operaciones**, la mayor parte se concentra en operaciones **aprobadas**, seguidas de un volumen menor de **operaciones declinadas** y un grupo más reducido de **operaciones pendientes**. Dentro de las operaciones aprobadas, el segmento de **fraude aprobado** es muy pequeño, lo que refuerza la idea de que la mayor parte del fraude se frena en fases previas del proceso de autorización.

Cuando se analiza la **evolución trimestral del fraude por año**, se observa que el ejercicio **2025** concentra la mayoría de las operaciones fraudulentas, con un crecimiento notable desde el primer trimestre y un ligero descenso hacia final de año. Los años **2024** y **2026** presentan volúmenes de fraude significativamente menores. Este patrón sugiere que, durante 2025, se produjo bien un aumento de la actividad fraudulenta, bien un mejor etiquetado y detección de los casos, o una combinación de ambos factores.

En conjunto, este primer panel muestra un escenario donde el fraude existe y tiene impacto económico relevante, pero donde los mecanismos de prevención y rechazo están jugando un papel clave para contener el riesgo.

---

## 2. Riesgo geográfico por país del comercio

El segundo panel se centra en el **fraude asociado al país del comercio**. A nivel agregado, el importe total de fraude vinculado a comercios asciende también a unos **7,19 millones de euros**, con una **tasa de fraude promedio por país cercana al 1,47 %**.

A nivel individual, aparecen dos países especialmente destacados:

- **Jersey** como **país con mayor importe de fraude**, lo que indica que, aunque no necesariamente tenga el mayor número de operaciones, las que resultan fraudulentas tienden a ser de importes elevados.
- **Honduras** como **país con mayor número de operaciones fraudulentas**, lo que apunta a una concentración de casos en volumen, aunque no necesariamente en importe medio.

El gráfico de **Top 10 de importe de fraude por país del comercio** pone de relieve otros países con importes significativos, como **China, Ukraine, Tajikistan, Turks and Caicos, Guyana, Puerto Rico o Timor-Leste**, entre otros. Esto indica que el fraude no se concentra en un único mercado, sino que se reparte entre múltiples países con distinta intensidad.

Por su parte, el gráfico de **número de operaciones fraudulentas por país** destaca a países como **Honduras, Hungary, Tajikistan, Antigua and Barbuda, Belarus, China, Guyana, Jersey o Spain**. Aquí el foco está en la **frecuencia** más que en el importe, lo que permite identificar mercados donde quizás el ticket medio es menor, pero la recurrencia del fraude es alta.

Finalmente, el gráfico de **Top 10 de tasa de fraude promedio por país** muestra países como **Belize, Bhutan, Egypt, Myanmar, Laos, Cambodia, Tajikistan, Honduras, Comoros, Antarctica o Russian Federation**, con tasas relativas de fraude muy por encima de la media. Estos países no solo registran fraude, sino que, en proporción a su volumen de operaciones, muestran una **probabilidad de fraude sensiblemente mayor**.

El mapa de **distribución geográfica del fraude** refuerza la idea de que el riesgo es global y se reparte entre distintas regiones, con una concentración visual apreciable en determinadas áreas. Desde el punto de vista de negocio, esto permite:

- Priorizar **controles adicionales** en países con alta tasa o alto importe de fraude.
- Revisar políticas comerciales, límites y requerimientos de autenticación para los mercados más expuestos.
- Analizar con mayor detalle la tipología de comercios y operaciones en estas geografías.

---

## 3. Perfil operacional por modo de entrada (entry\_mode)

El tercer panel analiza el fraude desde la perspectiva del **modo de entrada de la operación (entry\_mode)**. Los indicadores superiores muestran que:

- **wallet** aparece como el **modo de entrada líder en número de fraudes**, en **importe total de fraude** y en **importe medio por fraude**.
- **chip** destaca como el **modo de entrada con mayor número total de operaciones**, lo que sugiere un canal muy utilizado, aunque relativamente más seguro en términos de prevalencia de fraude.

El gráfico de **importe de fraude por entry\_mode** confirma que **wallet** concentra el mayor importe total de fraude, seguido de canales como **ecommerce, chip, magstripe y contactless**. Esto indica que las transacciones realizadas a través de billeteras digitales no solo son frecuentes, sino que tienden a asociarse a importes significativos cuando se produce fraude.

El gráfico de **número de operaciones fraudulentas por entry\_mode y resultado de la transacción** muestra cómo se reparte el fraude entre operaciones **aprobadas, declinadas y pendientes**. En la mayoría de los modos de entrada, se observa una combinación de fraudes que lograron ser aprobados y otros que quedaron declinados o en estado pendiente, lo que refleja la actuación de los mecanismos de control. No obstante, en canales como **wallet** y **contactless**, el volumen total de fraudes (sumando todas las etapas) es especialmente relevante.

El gráfico de **número de operaciones fraudulentas por entry\_mode** resume de forma clara que **wallet** es el canal con mayor número de fraudes, seguido de **contactless, magstripe, chip y ecommerce**. Sin embargo, cuando se observa el gráfico de **total de operaciones vs número de fraudes por entry\_mode**, se aprecia que:

- **chip** y **contactless** manejan un volumen muy alto de operaciones, con un número de fraudes importante pero relativamente contenido en proporción.
- **wallet** combina **alto volumen de operaciones** con **alta cantidad de fraudes**, lo que la convierte en un canal prioritario para la gestión del riesgo.
- **magstripe** y **ecommerce** muestran también niveles de riesgo relevantes, aunque con volúmenes algo menores.

En términos operativos, este panel sugiere que:

- **wallet** es el canal crítico donde reforzar controles, autenticaciones fuertes y monitorización en tiempo real.
- **chip** sigue siendo el modo de entrada más seguro en términos relativos, coherente con la tecnología EMV.
- Los canales más cómodos o digitales tienden a atraer mayor actividad fraudulenta y requieren una atención diferenciada.

---

## 4. Perfil de cliente y niveles de riesgo

El cuarto panel se centra en el **perfil del cliente y la relación con el riesgo**. A nivel de síntesis:

- El **nivel de riesgo que más fraudes concentra** es el **nivel Medio**, según el indicador principal.
- El **risk\_score medio de las operaciones fraudulentas** se sitúa en torno a **44 puntos**, lo que sugiere un nivel de riesgo apreciable pero no extremo.
- La **antigüedad media del cliente en fraudes** ronda los **122 días**, es decir, unos cuatro meses de relación con la entidad en el momento del fraude.
- La **región del cliente con mayor tasa de fraude** es **Gambia**, según el indicador destacado.

El gráfico de **tasa de fraude por nivel de riesgo (risk\_level)** muestra que el fraude no se concentra exclusivamente en el nivel Alto; de hecho, el nivel **Bajo** presenta una tasa de fraude ligeramente superior a la de los niveles Alto y Medio. Este resultado sugiere que el modelo de asignación de niveles de riesgo podría estar infraestimando el riesgo en determinados perfiles catalogados como Bajo, o que el fraude está explotando segmentos tradicionalmente considerados menos sospechosos.

En el gráfico de **tasa de fraude por región del cliente**, se observa que algunas regiones (como **Gambia, Marshall Islands, Sweden, Cambodia, Gabon, Jordan, Estonia y otras**) alcanzan tasas de fraude muy superiores a la media global. Estas regiones representan focos geográficos de especial sensibilidad, donde la probabilidad de fraude por cliente es significativamente mayor.

El análisis de **tasa de fraude por rango de antigüedad del cliente** revela un patrón claro: los clientes con **antigüedad entre 0 y 30 días** presentan la **tasa de fraude más elevada**, seguida de los rangos **91–180 días** y **31–90 días**. A medida que aumenta la antigüedad y se supera el año de relación, la tasa de fraude desciende de manera notable. Este comportamiento es consistente con la idea de que:

- Los clientes más recientes pueden incluir tanto cuentas nuevas genuinas como identidades robadas o sintéticas.
- Con el tiempo, los patrones de uso se estabilizan y los sistemas de monitorización disponen de más información para discriminar comportamientos anómalos.

Por último, el gráfico de **número de fraudes por región del cliente** muestra que algunas regiones o estados (como **Vermont, Colorado, Minnesota, Pennsylvania, Rhode Island, Alaska o Arkansas**) concentran un número significativo de fraudes. Aquí el foco está en el volumen absoluto de casos, no solo en la tasa relativa, lo que permite priorizar recursos de investigación y seguimiento.

---

## 5. Conclusiones generales

El conjunto de dashboards ofrece una visión integrada del fraude desde diferentes ángulos:

- **Globalmente**, el fraude tiene una tasa contenida en torno al 1,1 %, pero un **impacto económico relevante** de unos 7,19 millones de euros. Los sistemas de control muestran eficacia al mantener una **tasa mínima de fraude aprobado** y un volumen apreciable de fraude evitado.
- **Geográficamente**, el riesgo no es homogéneo: algunos países presentan **altos importes**, otros **muchas operaciones fraudulentas**, y otros **tasas relativas muy elevadas**. Esto hace necesario adaptar la estrategia de control por país.
- **Por canales de entrada**, **wallet** se consolida como el canal más crítico, al combinar alto volumen y alta incidencia de fraude, mientras que **chip** se mantiene como el modo de entrada relativamente más seguro.
- **En cuanto al perfil del cliente**, el fraude se concentra especialmente en **clientes recientes** y en determinadas **regiones**, y no exclusivamente en el nivel de riesgo Alto, lo que sugiere margen de mejora en la calibración del modelo de riesgo.

En términos de negocio, estos resultados permiten:

- Identificar **segmentos prioritarios de actuación** (países, canales, niveles de antigüedad y regiones específicas).
- Reforzar **reglas y controles dinámicos** en los puntos de mayor exposición (**wallet**, países y regiones con alta tasa, clientes de muy baja antigüedad).
- Utilizar el dashboard como herramienta recurrente para **monitorizar la evolución del fraude**, evaluar el impacto de nuevas medidas y apoyar la toma de decisiones en equipos de riesgo y operaciones.

En resumen, el análisis confirma que el fraude es un fenómeno focalizado en determinados segmentos y contextos, y que una gestión basada en datos permite orientar los esfuerzos de prevención hacia los puntos con mayor retorno potencial en reducción de riesgo.